

图神经网络





目录



图神经网络简介



谱图论（简要回顾）



图滤波



图池化






图表示的学习

数据降维

网络嵌入

图深度学习

Laplacian Eigenmap



Construct graph from data points
(capture local information)

Project points into a low-dim
space using "eigenvectors of
the graph"

[Image credit](#)

1970s

~2000

2000

2003

2006

Spectral
Clustering

IsoMap; LLE

Laplacian
Eigenmaps

Matrix
Factorization




图表示的学习

数据降维


网络嵌入

图深度学习

DeepWalk




(a) Random walk generation.



(b) Representation mapping.

[Image credit](#)






图表示的学习

数据降维

网络嵌入

图深度学习




[Image credit](#)

今天的主题


构建适合于图的深度神经网络！



图神经网络 (GNNs)




A



F

聚焦于节点的任务

图滤波



节点表示

聚焦于图的任务

图池化

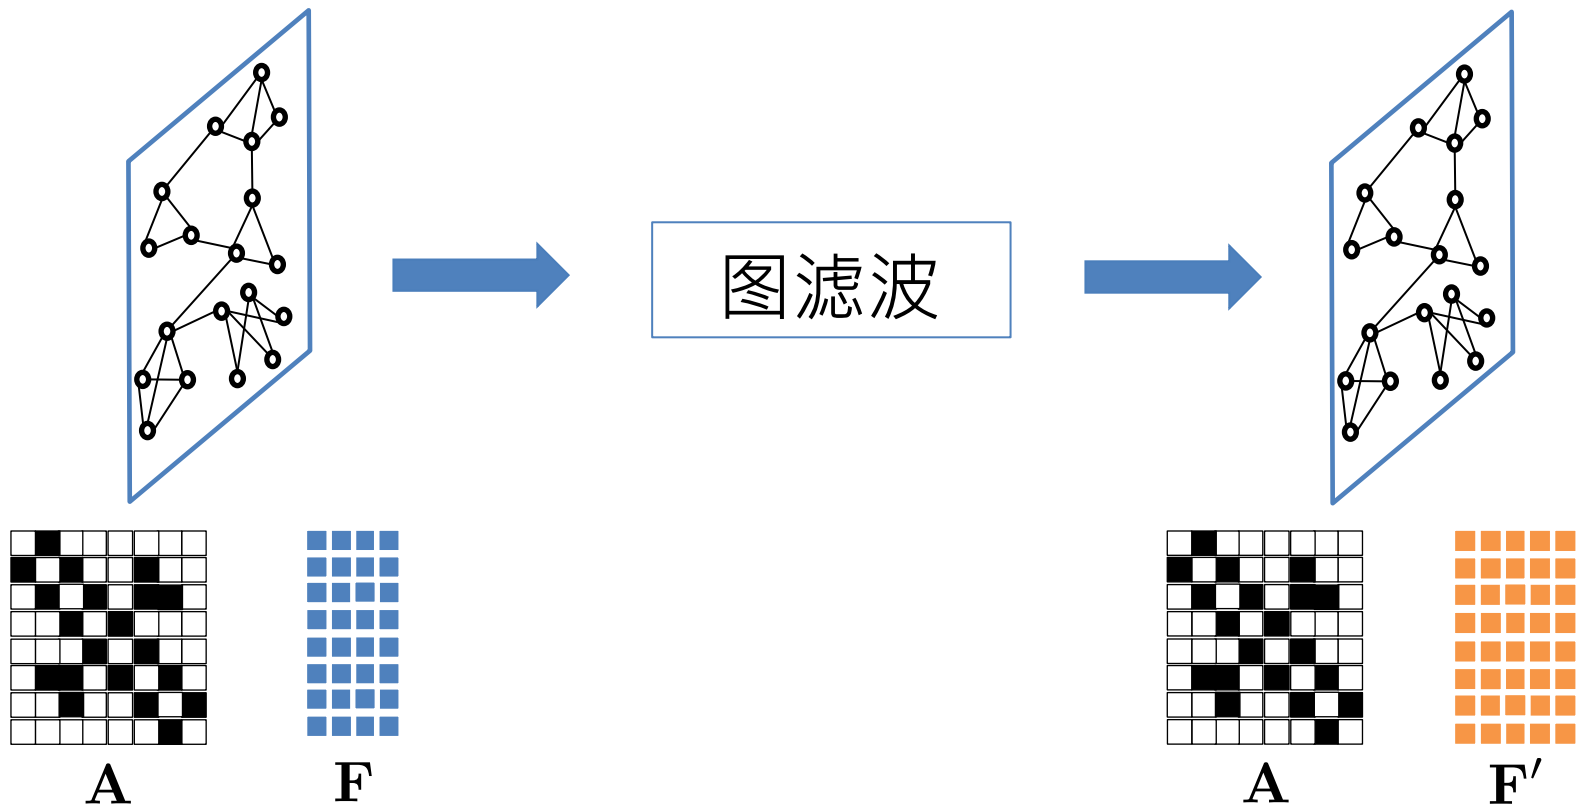


图表示





图滤波操作






通用的GNN框架（节点任务）



图滤波操作




激活函数







图池化操作




图池化




A



F



A_p



F'_p



通用的GNN框架（图任务）




图滤波操作



激活函数




图池化操作



B_1

...



B_n





目录



图神经网络简介



谱图论（简要回顾）



图滤波



图池化





拉普拉斯矩阵作为算子

拉普拉斯矩阵可以作为一个差分算子

$$\mathbf{h} = \mathbf{L}\mathbf{f} = (\mathbf{D} - \mathbf{A})\mathbf{f} = \mathbf{D}\mathbf{f} - \mathbf{A}\mathbf{f}$$


$$\mathbf{h}(i) = \sum_{v_j \in \mathcal{N}(v_i)} (\mathbf{f}(i) - \mathbf{f}(j))$$

拉普拉斯二次型


$$\mathbf{f}^T \mathbf{L} \mathbf{f} = \frac{1}{2} \sum_{i,j=1}^N \mathbf{A}[i,j] (\mathbf{f}(i) - \mathbf{f}(j))^2$$



- 衡量了图信号的“光滑度”或者“频率”
- 拉普拉斯矩阵为半正定矩阵



“光滑”的“低频”信号



“不光滑”的“高频”信号





拉普拉斯矩阵的特征分解

拉普拉斯矩阵有一套完整的标准正交的特征向量：

$$\mathbf{L} = \underbrace{\begin{bmatrix} | & & | \\ \mathbf{u}_0 & \cdots & \mathbf{u}_{N-1} \\ | & & | \end{bmatrix}}_{\mathbf{U}} \underbrace{\begin{bmatrix} \lambda_0 & & 0 \\ & \ddots & \\ 0 & & \lambda_{N-1} \end{bmatrix}}_{\mathbf{\Lambda}} \underbrace{\begin{bmatrix} \text{---} & \mathbf{u}_0 & \text{---} \\ & \vdots & \\ \text{---} & \mathbf{u}_{N-1} & \text{---} \end{bmatrix}}_{\mathbf{U}^T}$$

通常我们将这些特征向量按照特征值从小到大排列，


$$0 = \lambda_0 < \lambda_1 \leq \cdots \lambda_{N-1}$$






特征向量作为图上的信号

这些特征向量是图信号的一组基




低频

$$u_0^T L u_0 = \lambda_0 = 0$$



$$u_1^T L u_1 = \lambda_1$$



高频

$$u_7^T L u_7 = \lambda_7$$

频率： $u_i^T L u_i$



图傅立叶变换 (GFT)

任意的图信号 f 可以用图傅立叶级数表示


$$\mathbf{f} = \sum_{i=0}^{N-1} \hat{f}_i \cdot \mathbf{u}_i$$

$$\hat{f}_i = \mathbf{f}^\top \mathbf{u}_i$$

\mathbf{u}_i : 基 (特征向量)

λ_i : 基的频率 (特征值)


\hat{f}_i : 傅立叶系数



空间域: f

$$\hat{f} = U^\top f$$

分解图信号



谱域: \hat{f}



图傅立叶变换 (GFT)

任意的图信号 f 可以用图傅立叶级数表示

$$\mathbf{f} = \sum_{i=0}^{N-1} \hat{f}_i \cdot \mathbf{u}_i$$


$$\hat{f}_i = \mathbf{f}^\top \mathbf{u}_i$$

\mathbf{u}_i : 基 (特征向量)

λ_i : 基的频率 (特征值)

矩阵形式


\hat{f}_i : 傅立叶系数



空间域: f

$$\mathbf{f} = \mathbf{U} \hat{\mathbf{f}}$$

重建图信号



谱域: \hat{f}



目录



图神经网络简介



谱图论（简要回顾）



图滤波



图池化





两大类图滤波操作

基于空间的图滤波操作

在空间域上设计

基于谱的图滤波操作

在谱域上设计

最早的图滤波操作




基于谱的
图滤波操作



基于空间的图滤波操作



最早的图滤波操作



通常是上一个操作的输出

F_i : 图滤波操作的输入特征

l_i : 初始的节点特征

F'_i : 图滤波操作的输出特征

$$F'_i = \sum_{v_j \in N(v_i)} f(l_i, F_j, l_j), \quad \forall v_i \in V.$$

$f(\cdot)$: 通常是前馈神经网络




图谱滤波

图傅立叶变换


$$GFT: \hat{f} = U^T f$$

$$IGFT: f = U \hat{f}$$

图谱滤波



Filter $\hat{g}(\lambda_i)$: 调制信号中不同频率的部分






图谱滤波

图傅立叶变换

$$GFT: \hat{f} = U^T f$$


$$IGFT: f = U \hat{f}$$

图谱滤波



Filter $\hat{g}(\Lambda)$: 调制信号中不同频率的部分

$$\hat{g}(\Lambda) = \begin{bmatrix} \hat{g}(\lambda_0) & & 0 \\ & \ddots & \\ 0 & & \hat{g}(\lambda_{N-1}) \end{bmatrix}$$






将图谱滤波运用到GNN上


如何设计滤波器

$$\hat{g}(\Lambda) = \begin{bmatrix} \hat{g}(\lambda_0) & & 0 \\ & \ddots & \\ 0 & & \hat{g}(\lambda_{N-1}) \end{bmatrix}$$

从数据中学习



如何处理多通道信号



$$\mathbf{F} \in \mathbb{R}^{N \times d_1} \rightarrow \mathbf{F}' \in \mathbb{R}^{N \times d_2}.$$

每个输出通道都与所有输入通道相关

$$\mathbf{F}'_{:,i} = \sum_{j=1}^{d_1} \hat{g}_{ij}(\mathbf{L}) \mathbf{F}_{:,j} \quad i = 1, \dots, d_2$$

需要学习 $d_2 \times d_1$ 个滤波器



$\hat{g}(\Lambda)$: 非参数方法

$$\hat{g}(\Lambda) = \begin{bmatrix} \hat{g}(\lambda_0) & & 0 \\ & \ddots & \\ 0 & & \hat{g}(\lambda_{N-1}) \end{bmatrix}$$





$\hat{g}(\Lambda)$: 非参数方法

$$\hat{g}(\Lambda) = \begin{bmatrix} \theta_1 & & & \\ & \theta_2 & & \\ & & \dots & \\ & & & \theta_N \end{bmatrix}$$

$$\mathbf{U} \hat{g}(\Lambda) \mathbf{U}^T \mathbf{f}$$

$d_2 \times d_1 \times N$ 个参数

需要做矩阵分解，通常比较耗时





$\hat{g}(\Lambda)$: 利用多项式拟合

$$\hat{g}(\Lambda) = \begin{bmatrix} \sum_{k=0}^K \theta_k \lambda_1^k & \sum_{k=0}^K \theta_k \lambda_2^k & \dots & \sum_{k=0}^K \theta_k \lambda_N^k \end{bmatrix}$$

$$\mathbf{U} \hat{g}(\Lambda) \mathbf{U}^T \mathbf{f} = \sum_{k=0}^K \theta_k \mathbf{L}^k \mathbf{f}$$

$d_2 \times d_1 \times (K + 1)$ 个参数

不需要做特征分解





Chebyshev 多项式

$$g(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots$$

多项式的基： $1, x, x^2, x^3, \dots$

非正交

导致学习参数的过程不稳定

Chebyshev 多项式

以递归的形式定义:

- $T_0(x) = 1; T_1(x) = x$
- $T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x)$

这样定义的Chebyshev 多项式 $\{T_k\}$ 是希尔伯特空间 $L^2([-1,1], \frac{dy}{\sqrt{1-y^2}})$ 中的一组正交基。

$$g(x) = \theta_0 T_0(x) + \theta_1 T_1(x) + \theta_2 T_2(x) + \dots$$





Cheb-Filter

利用 Chebyshev 多项式来拟合 $\hat{g}(\Lambda)$

- ❑ 拉普拉斯矩阵的最大特征值
- ❑ 调整 $\tilde{\Lambda}$ 大小到 $[-1, 1]$ 的区间

$$\hat{g}(\Lambda) = \sum_{k=0}^K \theta_k T_k(\tilde{\Lambda}), \text{ with } \tilde{\Lambda} = \frac{2\Lambda}{\lambda_{max}} - 1$$

$$\mathbf{U} \hat{g}(\Lambda) \mathbf{U}^\top \mathbf{f} = \sum_{k=0}^K \theta_k T_k(\tilde{\mathbf{L}}) \mathbf{f}, \text{ with } \tilde{\mathbf{L}} = \frac{2\mathbf{L}}{\lambda_{max}} - \mathbf{I}$$

$d_2 \times d_1 \times (K + 1)$ 个参数

不需要做特征分解

学习参数的过程相对来说更稳定

Convolutional Neural Networks on Graphs with Fast Localized Spectral Filtering





GCN-Filter: 简化的Cheb-Filter

把Chebshev多项式的阶数设为一， $K = 1$ 。同时假设 $\lambda_{max} = 2$

$$\hat{g}(\Lambda) = \theta_0 + \theta_1(\Lambda - I)$$

进一步假设 $\theta = \theta_0 = -\theta_1$

$$\hat{g}(\Lambda) = \theta(2I - \Lambda)$$

$$U\hat{g}(\Lambda)U^T f = \theta(2I - L)f = \theta \left(I + D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \right) f$$


使用renormalization

$$U\hat{g}(\Lambda)U^T f = \theta \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} \right) f, \text{ with } \tilde{A} = A + I$$





处理多通道图信号的GCN-Filter



$$\mathbf{F} \in \mathbb{R}^{N \times d_1} \rightarrow \mathbf{F}' \in \mathbb{R}^{N \times d_2}.$$

GCN-Filter

每个输出通道都与所有输入通道相关

$$\mathbf{F}'_{:,i} = \sum_{j=1}^{d_1} \hat{g}_{ij}(\mathbf{L}) \mathbf{F}_{:,j} \quad i = 1, \dots, d_2$$

$$\mathbf{F}'_{:,i} = \sum_{j=1}^{d_1} \theta_{ji} (\tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}}) \mathbf{F}_{:,j} \quad i = 1, \dots, d_2$$

矩阵形式

$$\mathbf{F}' = (\tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}}) \mathbf{F} \mathbf{\Theta} \text{ with } \mathbf{\Theta} \in \mathbb{R}^{d_1 \times d_2} \text{ and } \mathbf{\Theta}[j, i] = \theta_{ji}$$



从空间域理解GCN-Filter


$$\text{令 } \hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$$

- 那么 $\mathbf{F}' = \hat{\mathbf{A}} \mathbf{F} \Theta$
- 对于节点 v_i , $\mathbf{F}'_i = \sum_j \hat{A}[i, j] \mathbf{F}_j \Theta$

可以观察到

$$\hat{A}[i, j] = 0 \text{ for } v_j \notin N(v_i) \cup \{v_i\}$$


从空间域理解



$$\mathbf{F}'_i = \sum_j \hat{A}[i, j] \mathbf{F}_j \Theta = \sum_{v_j \in N(v_i) \cup \{v_i\}} \hat{A}[i, j] \mathbf{F}_j \Theta$$



GraphSage-Filter



聚合函数：如求和，求平均，LSTM等

采样

$$\mathcal{N}_S(v_i) = \text{SAMPLE}(\mathcal{N}(v_i), S)$$

采样数量

聚合

$$f'_{\mathcal{N}_S(v_i)} = \text{AGG}(\{F_j, \forall v_j \in \mathcal{N}_S(v_i)\})$$


$$F'_i = \sigma\left([F_i, f'_{\mathcal{N}_S(v_i)}] \Theta\right)$$

Inductive Representation Learning on Large graphs






GAT-Filter



GCN-Filter: $F'_i = \sum_{v_j \in \mathcal{N}(v_i) \cup \{v_i\}} \hat{A}[i, j] F_j \Theta$

GAT-Filter: $F'_i = \sum_{v_j \in \mathcal{N}(v_i) \cup \{v_i\}} \alpha_{ij} F_j \Theta$

$$\alpha_{ij} = \frac{\exp \left(\text{LeakyReLU} \left(\vec{a}^\top \left[\Theta \vec{F}_i \parallel \Theta \vec{F}_j \right] \right) \right)}{\sum_{k \in \mathcal{N}(v_i) \cup \{v_i\}} \exp \left(\text{LeakyReLU} \left(\vec{a}^\top \left[\Theta \vec{F}_i \parallel \Theta \vec{F}_k \right] \right) \right)}$$




边有不同的类型

$$\mathbf{F}'_i = \frac{1}{|\mathcal{N}(v_i)|} \sum_{v_j \in \mathcal{N}(v_i)} \mathbf{F}_j \Theta_{\text{tp}(v_i, v_j)}$$

针对某种特定边的类型的参数矩阵






针对某种特定边的类型的参数矩阵

$$\mathbf{m}_i = \sum_{(v_j, v_i) \in \mathcal{E}} \Theta_{\text{tp}(v_j, v_i)}^e \mathbf{F}_j$$

$$\mathbf{F}'_i = \text{GRU}(\mathbf{m}_i, \mathbf{F}_i)$$






信息传递

$$\mathbf{m}_i = \sum_{v_j \in \mathcal{N}(v_i)} M(\mathbf{F}_i, \mathbf{F}_j, \mathbf{e}_{(v_i, v_j)})$$

更新函数

$$\mathbf{F}'_i = U(\mathbf{F}_i, \mathbf{m}_i)$$

$M_k()$ 和 $U_k()$ 是需要进一步设计的函数



$$\text{GCN-Filter: } F'_i = \sum_{v_j \in N(v_i) \cup \{v_i\}} \hat{A}[i, j] F_j \Theta$$



从周围节点聚合

$$\text{PPNP: } F'_i = \sum_{v_j \in \mathcal{V}} P[i, j] F_j \Theta$$



可以换成MLP

$$\mathbf{P} = \beta(\mathbf{I} - (1 - \beta)\hat{\mathbf{A}})^{-1}$$

Personalized PageRank

Predict then Propagate: Graph Neural Networks meet Personalized PageRank





APPNP

PPNP: $F'_i = \sum_{v_j \in \mathcal{V}} P[i, j] F_j \Theta$ 矩阵形式 \rightarrow $F' = P F \Theta$ $\leftrightarrow F_{tr}$

\updownarrow

$P = \beta(\mathbf{I} - (1 - \beta)\hat{\mathbf{A}})^{-1}$

计算复杂

可拓展性差

APPNP: 用迭代的方式逼近 F'

$$\mathbf{F}_{out}^{(k)} = (1 - \beta)\hat{\mathbf{A}}\mathbf{F}_{out}^{(k-1)} + \beta\mathbf{F}_{tr} \quad k = 1, \dots, K$$

收敛


$$\mathbf{F}' = \mathbf{F}_{out}^{(K)} \xrightarrow{K \rightarrow \infty} \mathbf{F}' = P\mathbf{F}_{tr}$$





从图信号降噪的角度理解图滤波

图滤波操作



图信号降噪

A Unified View on Graph Neural Networks as Graph Signal Denoising



一些滤波操作的简单回顾

特征转换 $\mathbf{F}_{tr} = \mathbf{F}\Theta$

GCN

$$\mathbf{F}' = \hat{\mathbf{A}}\mathbf{F}_{tr}$$

GAT

$$\mathbf{F}'_i = \sum_{v_j \in \mathcal{N}(v_i) \cup \{v_i\}} \alpha_{ij} \mathbf{F}_{tr}$$

PPNP

$$\mathbf{F}' = \mathbf{P}\mathbf{F}_{tr}$$

APPNP


$$\mathbf{F}_{out}^{(k)} = (1 - \beta) \hat{\mathbf{A}} \mathbf{F}_{out}^{(k-1)} + \beta \mathbf{F}_{tr}$$
$$\mathbf{F}' = \mathbf{F}_{out}^{(K)}$$






图信号降噪

“Noisy Signal”



\mathbf{F}_{tr}

图



“节点和它的邻居相似”

“Clean Signal”



\mathbf{F}'

$$\arg \min_{\mathbf{F}'} \mathcal{L}(\mathbf{F}') = \underbrace{\|\mathbf{F}' - \mathbf{F}_{tr}\|_F^2}_{\text{Close to the input}} + c \cdot \underbrace{\frac{1}{2} \sum_{i \in \mathcal{V}} \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \|\mathbf{F}'_i - \mathbf{F}'_j\|_2^2}_{\text{Enforce the prior}}$$


Close to the input

Enforce the prior




图信号降噪

“Noisy Signal”




\mathbf{F}_{tr}

图



“Clean Signal”



\mathbf{F}'


“节点和它的邻居相似，相似程度可能不同”

$$\arg \min_{\mathbf{F}'} \mathcal{L}(\mathbf{F}') = \|\mathbf{F}' - \mathbf{F}_{tr}\|_F^2 + \frac{1}{2} \sum_{i \in \mathcal{N}(i)} c_i \cdot \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}} \|\mathbf{F}'_i - \mathbf{F}'_j\|_2^2$$



从图降噪角度理解PPNP

Filtering Operations





从图降噪角度理解PPNP

$$\arg \min_{\mathbf{F}'} \mathcal{L}(\mathbf{F}') = \|\mathbf{F}' - \mathbf{F}_{tr}\|_F^2 + c \cdot \frac{1}{2} \sum_{i \in \mathcal{V}} \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \|\mathbf{F}'_i - \mathbf{F}'_j\|_2^2$$

精确解:

$$\mathbf{F}' = \frac{1}{1+c} \left(\mathbf{I} - \frac{c}{1+c} \hat{\mathbf{A}} \right)^{-1} \mathbf{F}_{tr}$$

$$\text{Set } \beta = \frac{1}{1+c}$$

PPNP:

$$\mathbf{F}' = \mathbf{P} \mathbf{F}_{tr}$$



$$\mathbf{P} = \beta (\mathbf{I} - (1-\beta) \hat{\mathbf{A}})^{-1}$$





从图降噪角度理解GCN

Filtering Operations



Graph Signal Denoising





从图降噪角度理解GCN

$$\arg \min_{\mathbf{F}'} \mathcal{L}(\mathbf{F}') = \|\mathbf{F}' - \mathbf{F}_{tr}\|_F^2 + c \cdot \frac{1}{2} \sum_{i \in \mathcal{V}} \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \|\mathbf{F}'_i - \mathbf{F}'_j\|_2^2$$

Gradient Descent:

$$\mathbf{F}' \leftarrow \mathbf{F}_{tr} - b \cdot \left. \frac{\partial \mathcal{L}}{\partial \mathbf{F}'} \right|_{\mathbf{F}' = \mathbf{F}_{tr}} = (1 - 2bc)\mathbf{F}_{tr} + 2bc\hat{\mathbf{A}}\mathbf{F}_{tr}$$

$$\text{Set } b = \frac{1}{2c}$$



GCN: $\mathbf{F}' = \hat{\mathbf{A}}\mathbf{F}_{tr}$





从图降噪角度理解GAT

Filtering Operations



Graph Signal Denoising



从图降噪角度理解GAT

$$\arg \min_{\mathbf{F}'} \mathcal{L}(\mathbf{F}') = \|\mathbf{F}' - \mathbf{F}_{tr}\|_F^2 + \frac{1}{2} \sum_{i \in \mathcal{N}(i)} c_i \cdot \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}} \|\mathbf{F}'_i - \mathbf{F}'_j\|_2^2$$

Gradient Descent (针对第*i*个节点):

$$\mathbf{F}'_i \leftarrow \mathbf{F}_{tr}[i, :] - b_i \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{F}'_i} \bigg|_{\mathbf{F}'_i = \mathbf{F}_{tr}[i, :]}$$

$$= \left(1 - b_i \sum_{j \in \mathcal{N}(i)} (c_i + c_j) \right) \mathbf{F}_{tr}[i, :] + \sum_{j \in \mathcal{N}(i)} b_i (c_i + c_j) \mathbf{F}_{tr}[j, :]$$


$$\text{Set } \sum_{j \in \mathcal{N}(i)} b_i (c_i + c_j) = 1$$





从图降噪角度理解GAT

Gradient Descent Solution to Graph Signal Denoising:



$$\mathbf{F}'_i \leftarrow \sum_{j \in \mathcal{N}(i)} b_i (c_i + c_j) \mathbf{F}_{tr}[j, :] \quad \text{where} \quad \sum_{j \in \mathcal{N}(i)} b_i (c_i + c_j) = 1$$

Let $\alpha_{ij} = b_i (c_i + c_j)$

$$\mathbf{F}'_i = \sum_{j \in \mathcal{N}(i)} \alpha_{ij} \mathbf{F}_{tr}[j, :] \quad \text{where} \quad e_{ij} = f(\mathbf{F}_{tr}[i, :], \mathbf{F}_{tr}[j, :])$$
$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

GAT:





一个统一的理解

Graph Convolutional Networks (GCN)

Graph Attention Networks (GAT)

Personalized Propagation of Neural Predictions (PPNP)

⋮




图信号降噪






一个统一的框架：UGNN


“Noisy Signal”



图



“Clean Signal”



$$\arg \min_{\mathbf{F}'} \mathcal{L}(\mathbf{F}') = \|\mathbf{F}' - \mathbf{F}_{tr}\|_F^2 + \mathcal{R}(\mathbf{F}') \quad (1)$$

Enforce the prior

GCN, PPNP:

$$\mathcal{R}(\mathbf{F}') = c \cdot \frac{1}{2} \sum_{i \in \mathcal{V}} \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \|\mathbf{F}'_i - \mathbf{F}'_j\|_2^2$$

GAT:


$$\mathcal{R}(\mathbf{F}') = \frac{1}{2} \sum_{i \in \mathcal{N}(i)} c_i \cdot \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \|\mathbf{F}'_i - \mathbf{F}'_j\|_2^2$$






利用UGNN设计新的图滤波操作


“Noisy Signal”



图



“Clean Signal”



$$\arg \min_{\mathbf{F}'} \mathcal{L}(\mathbf{F}') = \|\mathbf{F}' - \mathbf{F}_{tr}\|_F^2 + \mathcal{R}(\mathbf{F}') \quad (1)$$



Design new $\mathcal{R}(\mathbf{F}')$ \longrightarrow Solve (1) \longrightarrow Novel graph filtering






Graph Trend Filtering

“Noisy Signal”



“Prior Information”

“Clean Signal”



$$\arg \min_{\mathbf{F}'} \mathcal{L}(\mathbf{F}') = \|\mathbf{F}' - \mathbf{F}_{tr}\|_F^2 + \mathcal{R}(\mathbf{F}') \quad (1)$$

$$\mathcal{R}(\mathbf{F}') = c \cdot \frac{1}{2} \sum_{i \in \mathcal{V}} \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \|\mathbf{F}'_i - \mathbf{F}'_j\|_1$$



目录



图神经网络简介



谱图论（简要回顾）



图滤波




图池化







图池化操作




图池化




A



F



A_p



F'_p



通用的GNN框架（图任务）




图滤波操作



激活函数



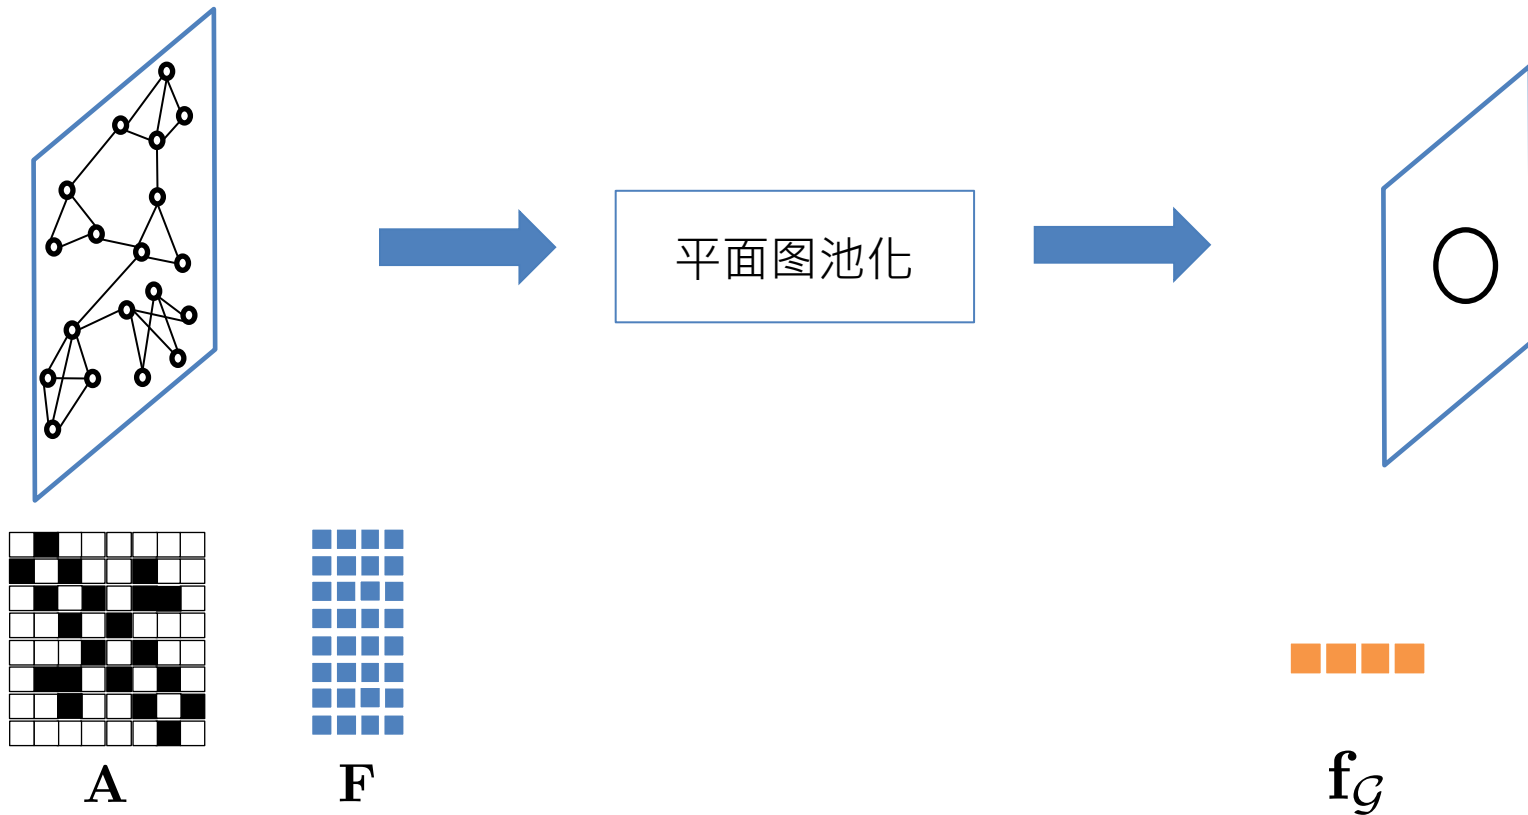
图池化操作



这个过程是层次化的




平面池化






平均池化和最大池化





添加虚拟节点进行池化




- ❑ 往图中添加一个虚拟节点
- ❑ 使这个虚拟节点与原图中所有节点连接

在新的图上更新节点表示




虚拟节点

作为图的表示 f_G






基于注意力机制的平面池化







层次图化操作




层次图池化



A



F




A_p



F'_p



选择最重要的节点来作为粗化图的节点



生成粗化图

A_p F'_p

重要性的度量

$$v_i \rightarrow y_i \quad y_i = \frac{F_i^\top p}{\|p\|}$$

选择重要性最高的 n_p 个节点

$$idx = rank(y, n_p)$$

生成粗化图的结构以及备用的节点特征

$$A_p = A[idx, idx]$$

$$F_{inter} = F[idx, :]$$

生成粗化图的节点特征


$$\tilde{y} = sigmoid(y[idx])$$

$$F'_p = F_{inter} \odot \tilde{y}$$





选择最重要的节点来作为粗化图的节点



生成粗化图

 A_p
 F'_p

重要性的度量

$$y = \alpha(\text{GCN-Filter}(A, F))$$

$$v_i \rightarrow y_i \quad y_i = \frac{F_i^\top p}{\|p\|}$$

选择重要性最高的 n_p 个节点

$$idx = \text{rank}(y, n_p)$$

生成粗化图的结构以及备用的节点特征

$$A_p = A[idx, idx]$$

$$F_{inter} = F[idx, :]$$

生成粗化图的节点特征


$$\tilde{y} = \text{sigmoid}(y[idx])$$

$$F'_p = F_{inter} \odot \tilde{y}$$





利用GNN生成子图来作为粗化图的节点



生成一个分配
矩阵

两个GCN模型

$$S = \text{softmax}(\text{GCN}(A, F))$$

$$S \in \mathbb{R}^{N \times n_p}$$

S_{ij} 表示把节点 v_i 分配给第 j 个子图的部分


生成备用节点
特征

$$F_{inter} = \text{GCN}(A, F)$$





利用GNN生成子图来作为粗化图的节点



生成粗化图

\mathbf{A}_p

\mathbf{F}'_p

利用学到的 \mathbf{S} 和 \mathbf{F}_{inter} 生成 \mathbf{A}_p 和 \mathbf{F}'_p


$$\mathbf{A}_p = \mathbf{S}^\top \mathbf{A} \mathbf{S}$$

$$\mathbf{F}'_p = \mathbf{S}^\top \mathbf{F}_{inter}$$






Eigenpooling



生成粗化图

A_p

F'_p




利用聚类方法学习到子图作为粗化图的节点，并生成相应的 A_p

- ❑ 主要关注学习 F'_p 的过程
- ❑ 学习 F'_p 的过程中需要捕捉结构和节点特征信息




傅立叶变换的简要回顾



空间域

傅立叶变换


傅立叶逆变换




谱域




信号重建的一个示例



GFT



IGFT

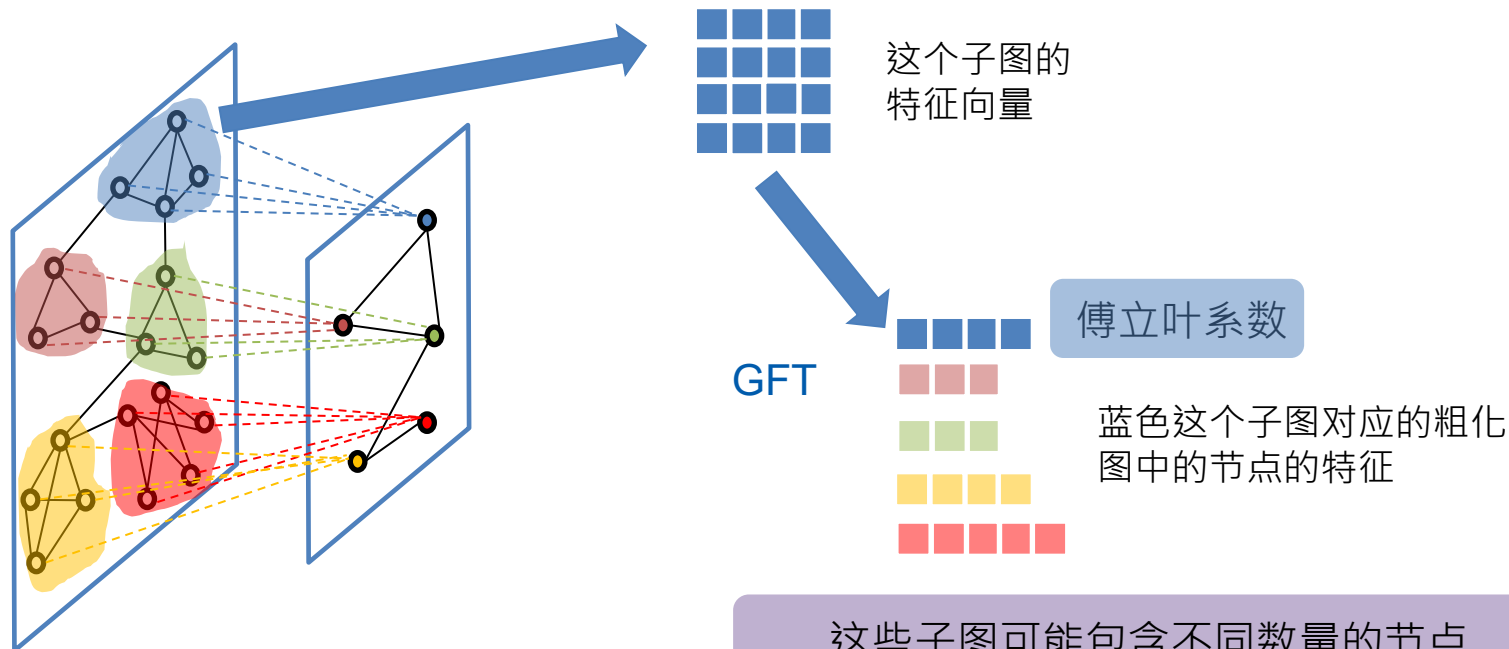


图傅立叶系数





Eigenpooling: 用傅立叶系数作为特征




这些子图可能包含不同数量的节点

计算所有的特征向量可能比较费时




信号重建的一个示例

真的需要用到所有的傅立叶系数来重建一个“不错”的信号吗？




GFT

图傅立叶系数




IGFT






信号重建的一个示例

真的需要用到所有的傅立叶系数来重建一个“不错”的信号吗？




GFT

截断的图傅立叶系数




IGFT





Eigenpooling: 用截断的傅立叶系数作为特征





目录



图神经网络简介



谱图论（简要回顾）



图滤波



图池化

