

图上的其他深度模型


教材：图深度学习，电子工业出版社
<https://baike.baidu.com/item/图深度学习>



 图上的循环神经网络

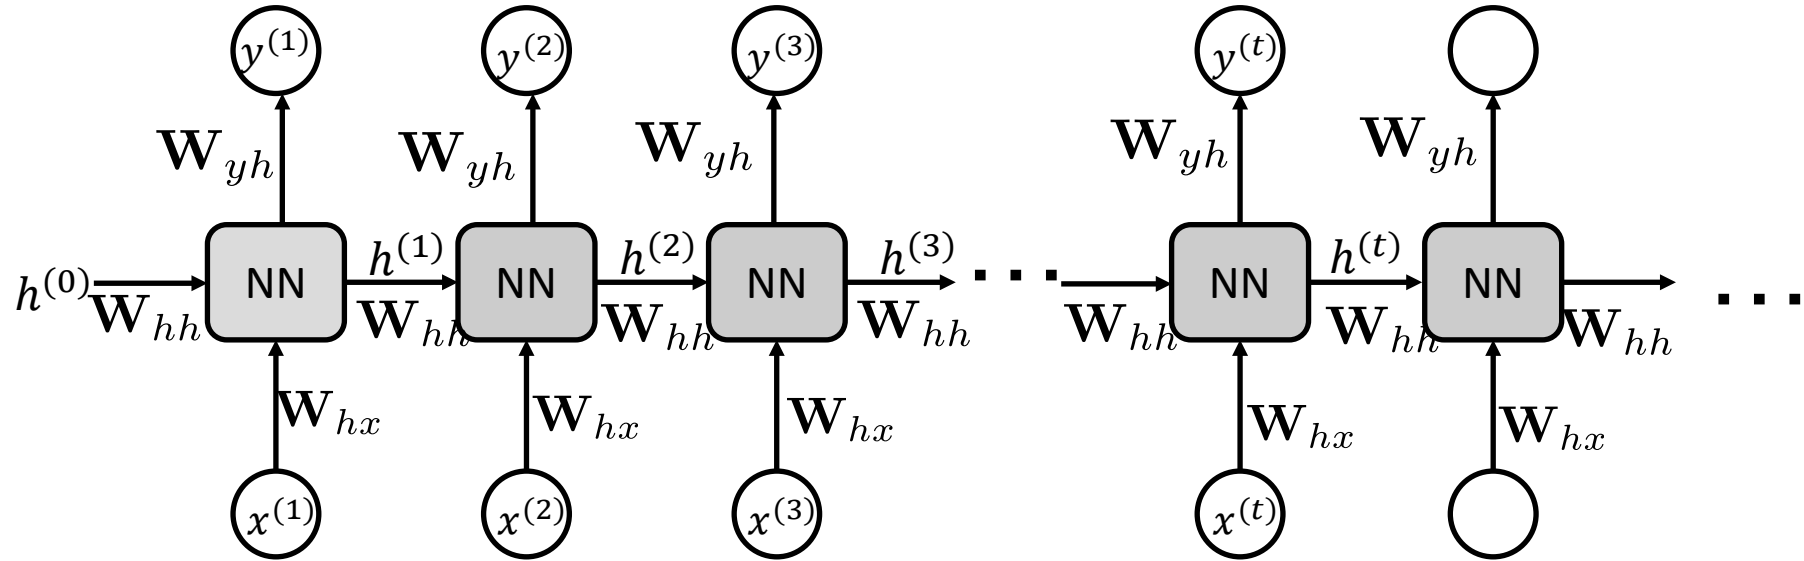
 图上的自编码器

 图上的变分自编码器

 图上的生成对抗网络




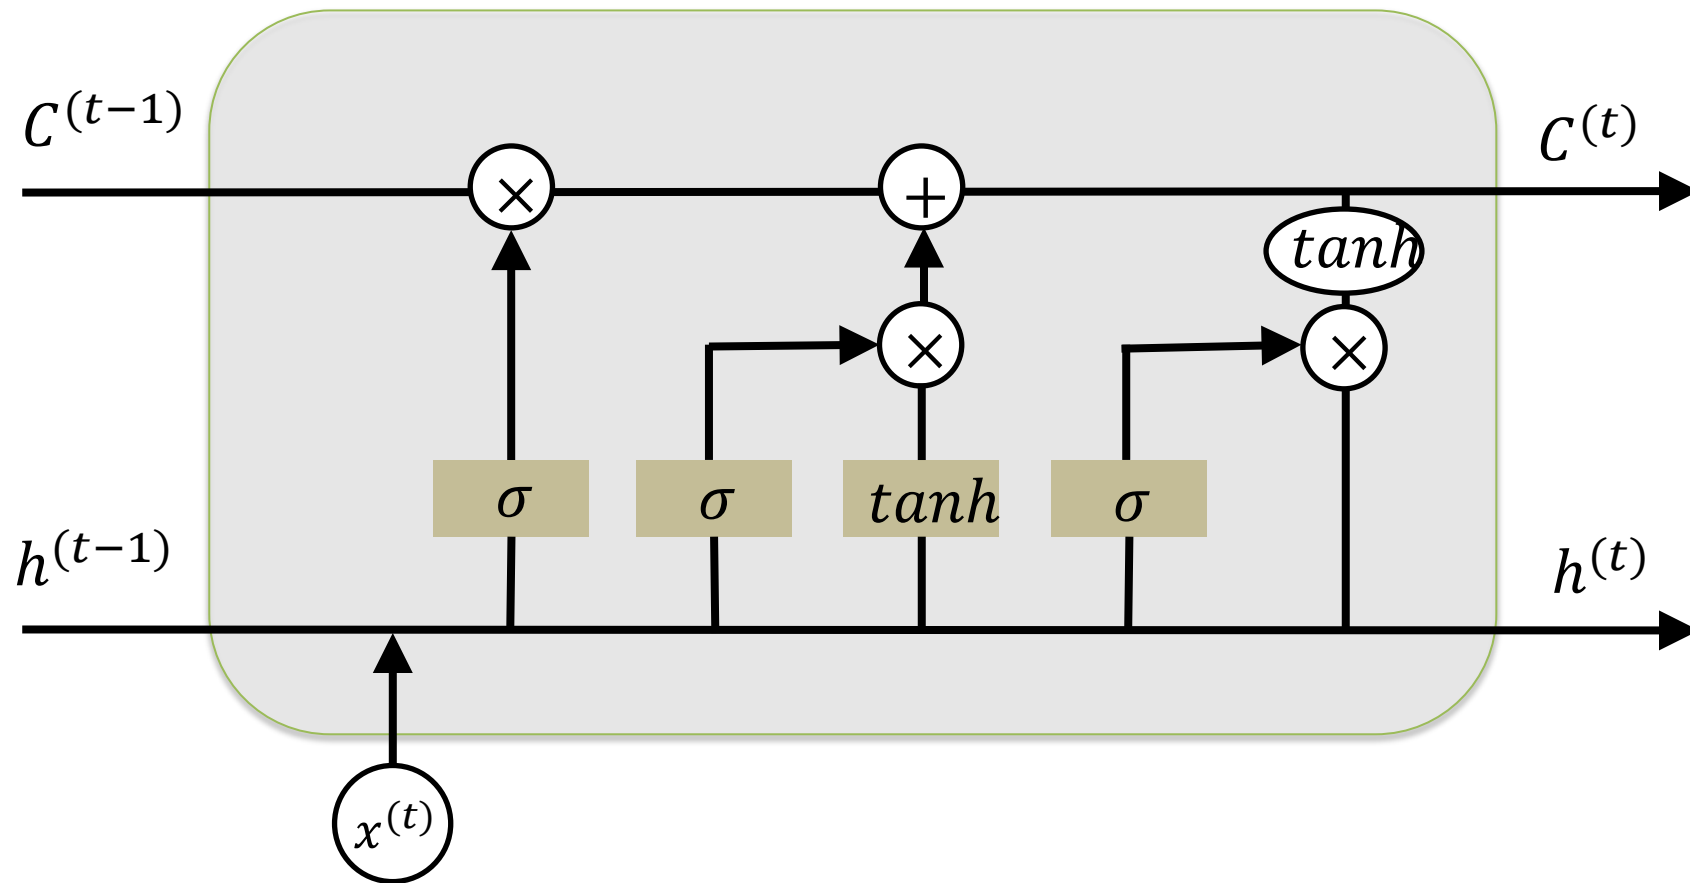
循环神经网络



$$h^{(i)} = \alpha_h \left(W_{hh} \cdot h^{(i-1)} + W_{hx} x^{(i-1)} + b_h \right)$$
$$y^{(i)} = \alpha_y \left(W_{yh} h^{(i)} + b_y \right)$$





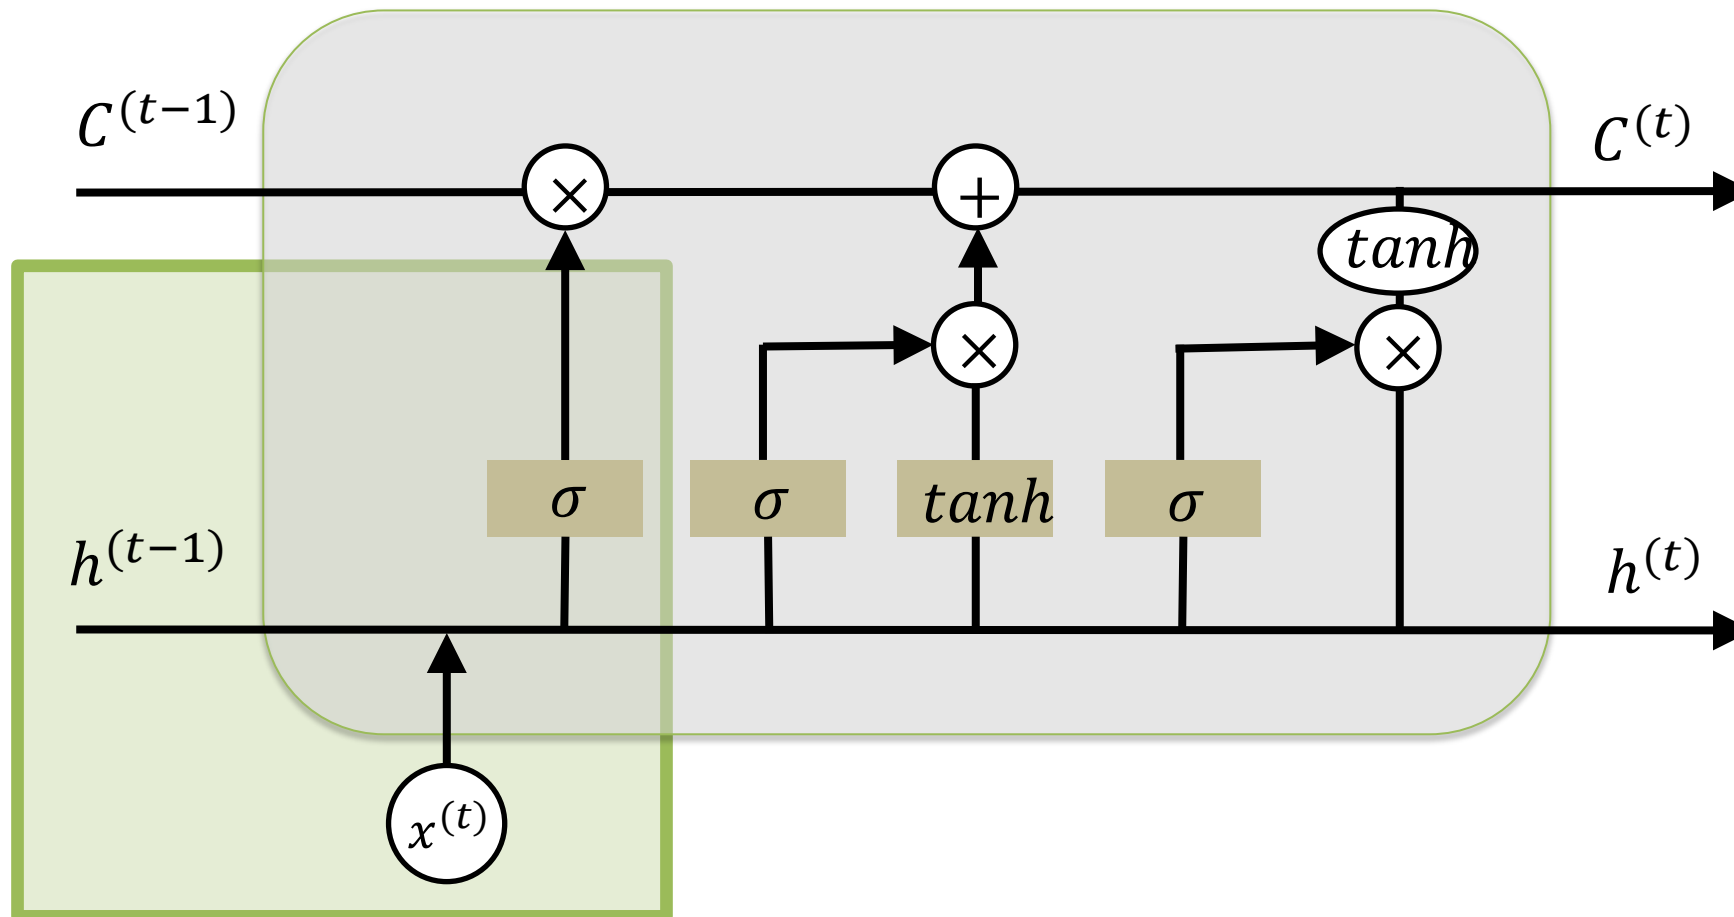


单元状态 (Cell State): $c^{(t)}$

隐藏状态 (Hidden State): $h^{(t)}$



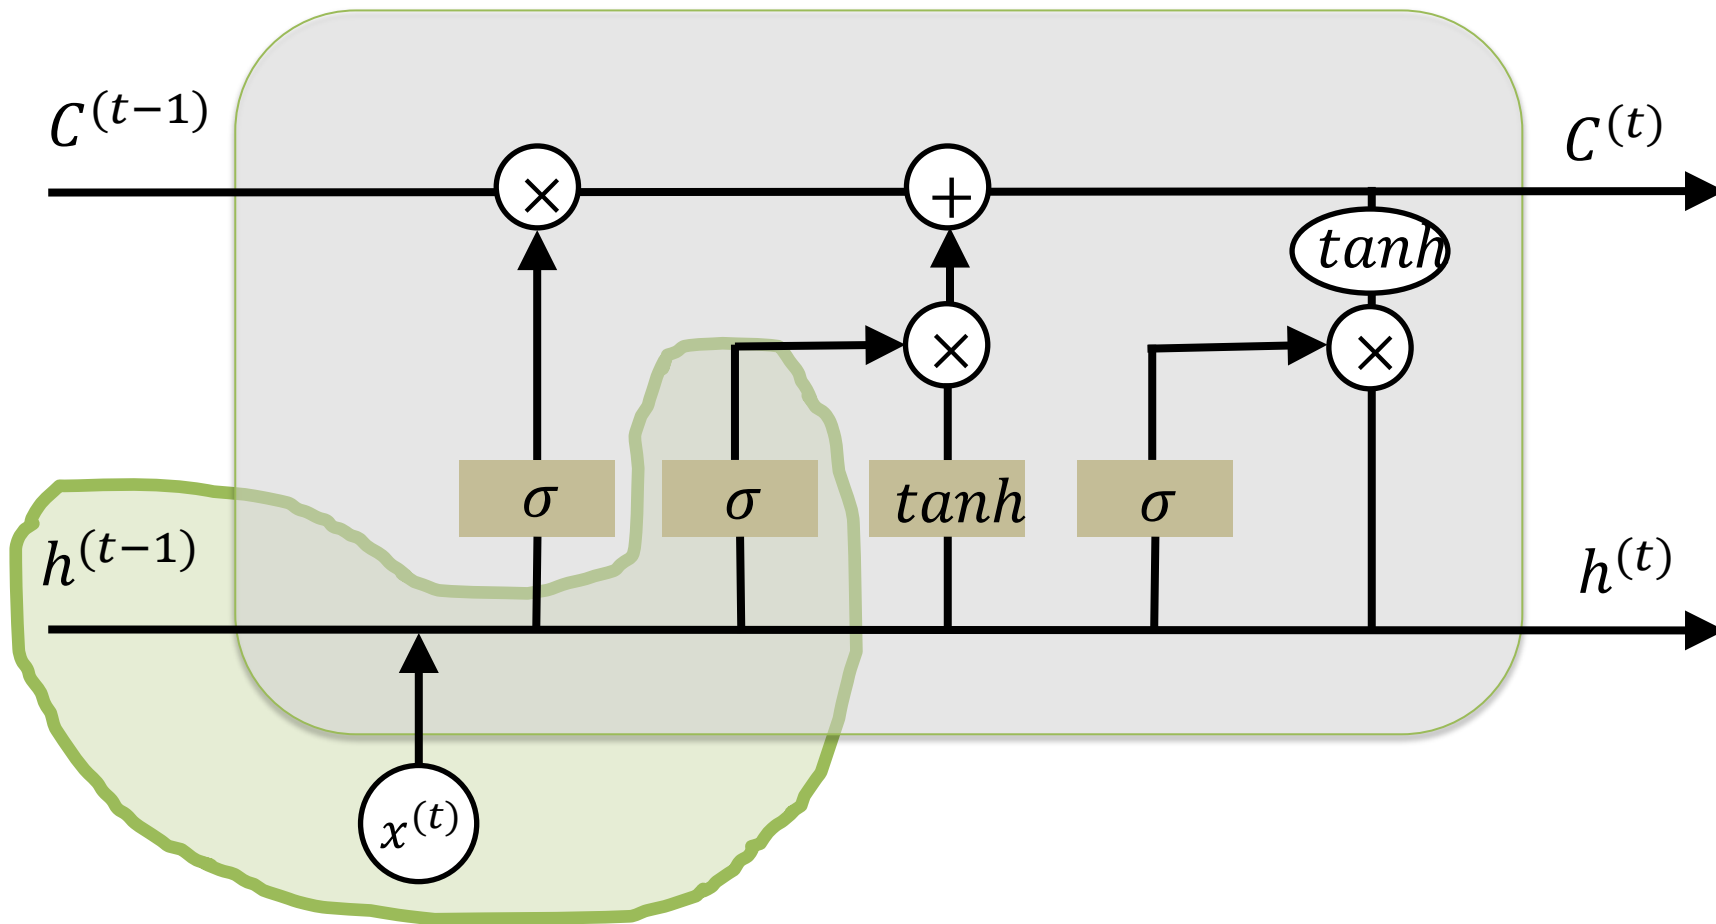
LSTM: 遗忘门




$$f_t = \sigma \left(\mathbf{W}_f \cdot \mathbf{x}^{(t)} + \mathbf{U}_f \cdot \mathbf{h}^{(t-1)} + \mathbf{b}_f \right)$$



LSTM: 输入门




$$i_t = \sigma \left(\mathbf{W}_i \cdot \mathbf{x}^{(t)} + \mathbf{U}_i \cdot \mathbf{h}^{(t-1)} + \mathbf{b}_i \right)$$





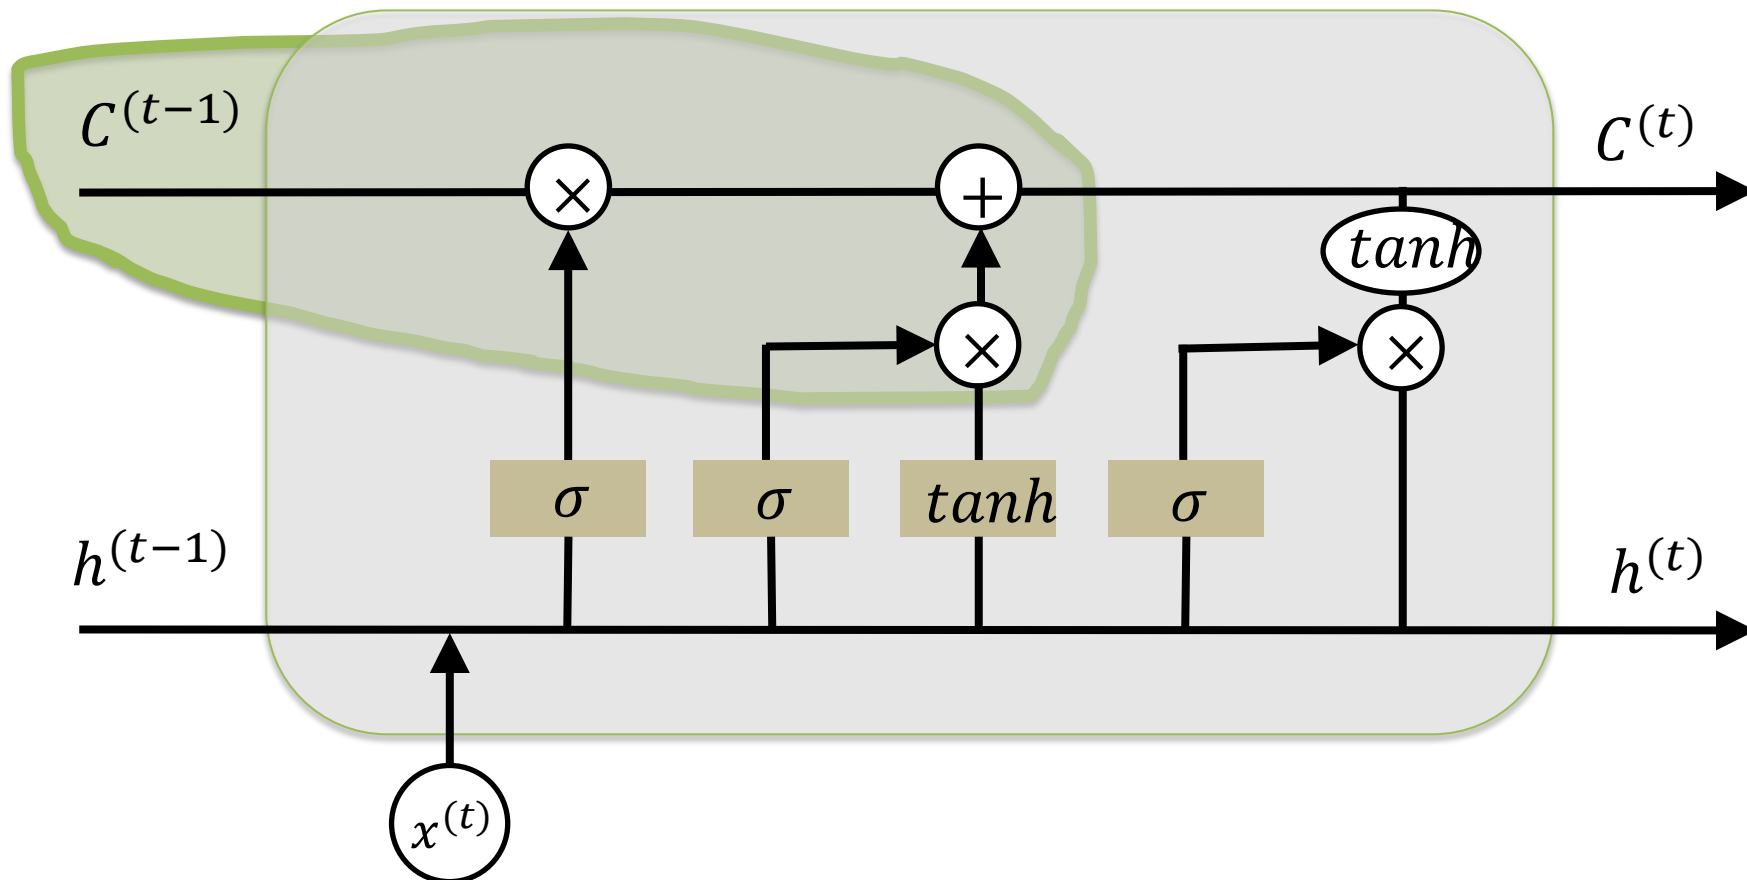
LSTM: 候选值




$$\tilde{C}^{(t)} = \tanh \left(\mathbf{W}_c \cdot \mathbf{x}^{(t)} + \mathbf{U}_c \cdot \mathbf{h}^{(t-1)} + \mathbf{b}_c \right)$$



LSTM: 新的单元状态

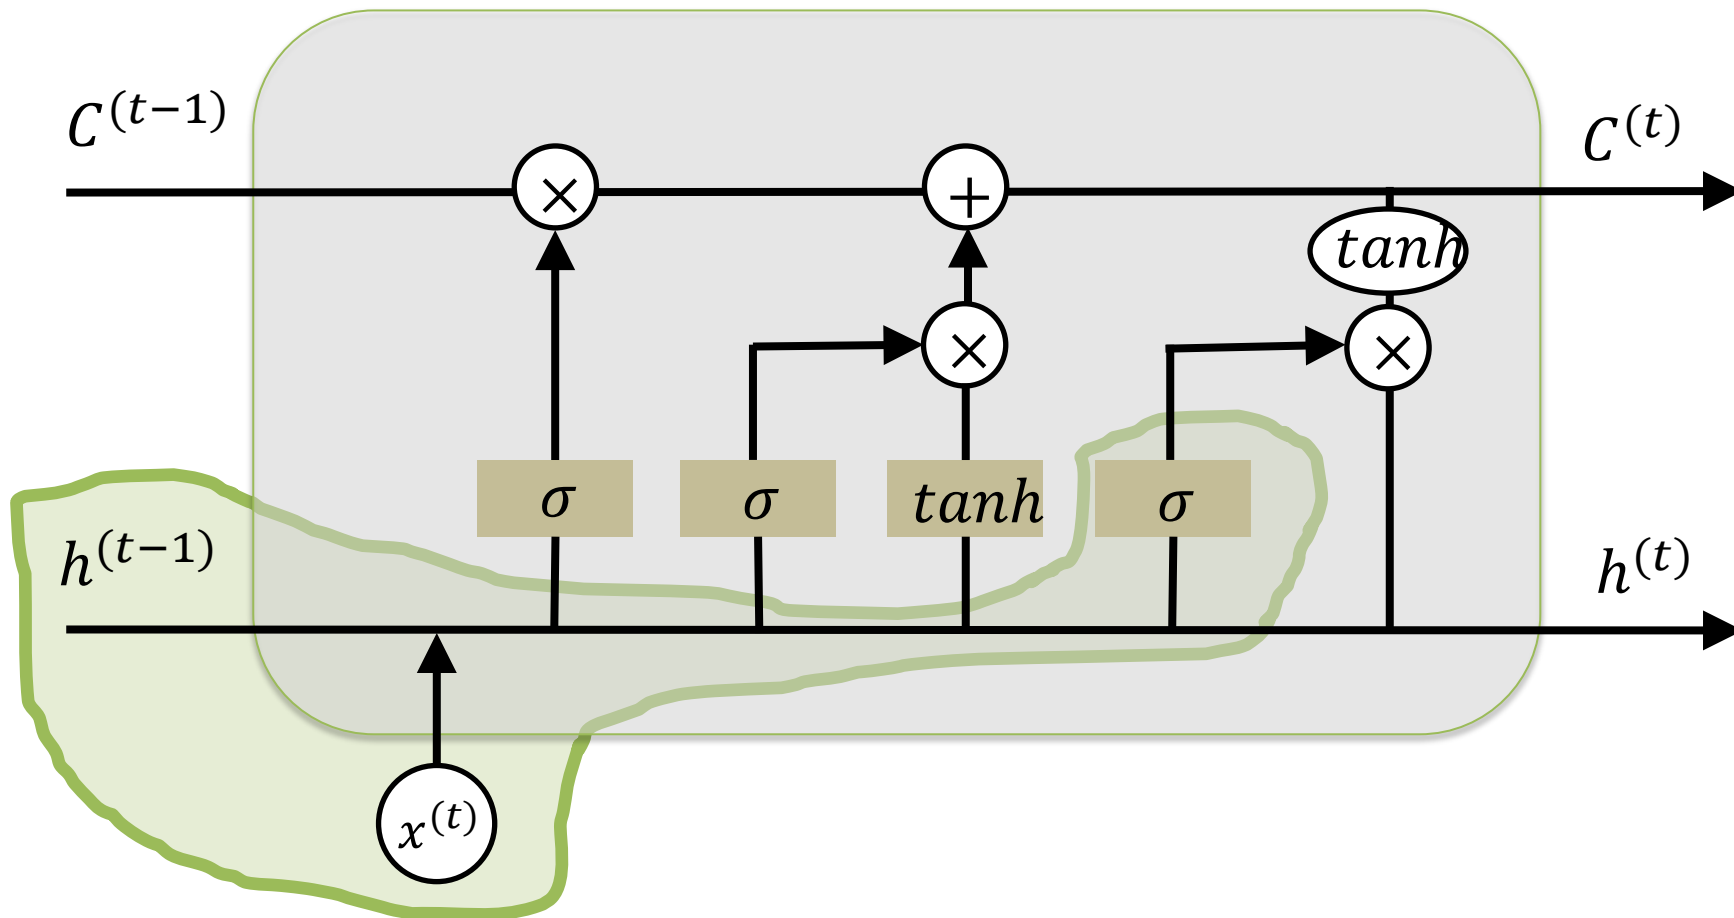


$$C^{(t)} = f_t \odot C^{(t-1)} + i_t \odot \tilde{C}^{(t)}$$




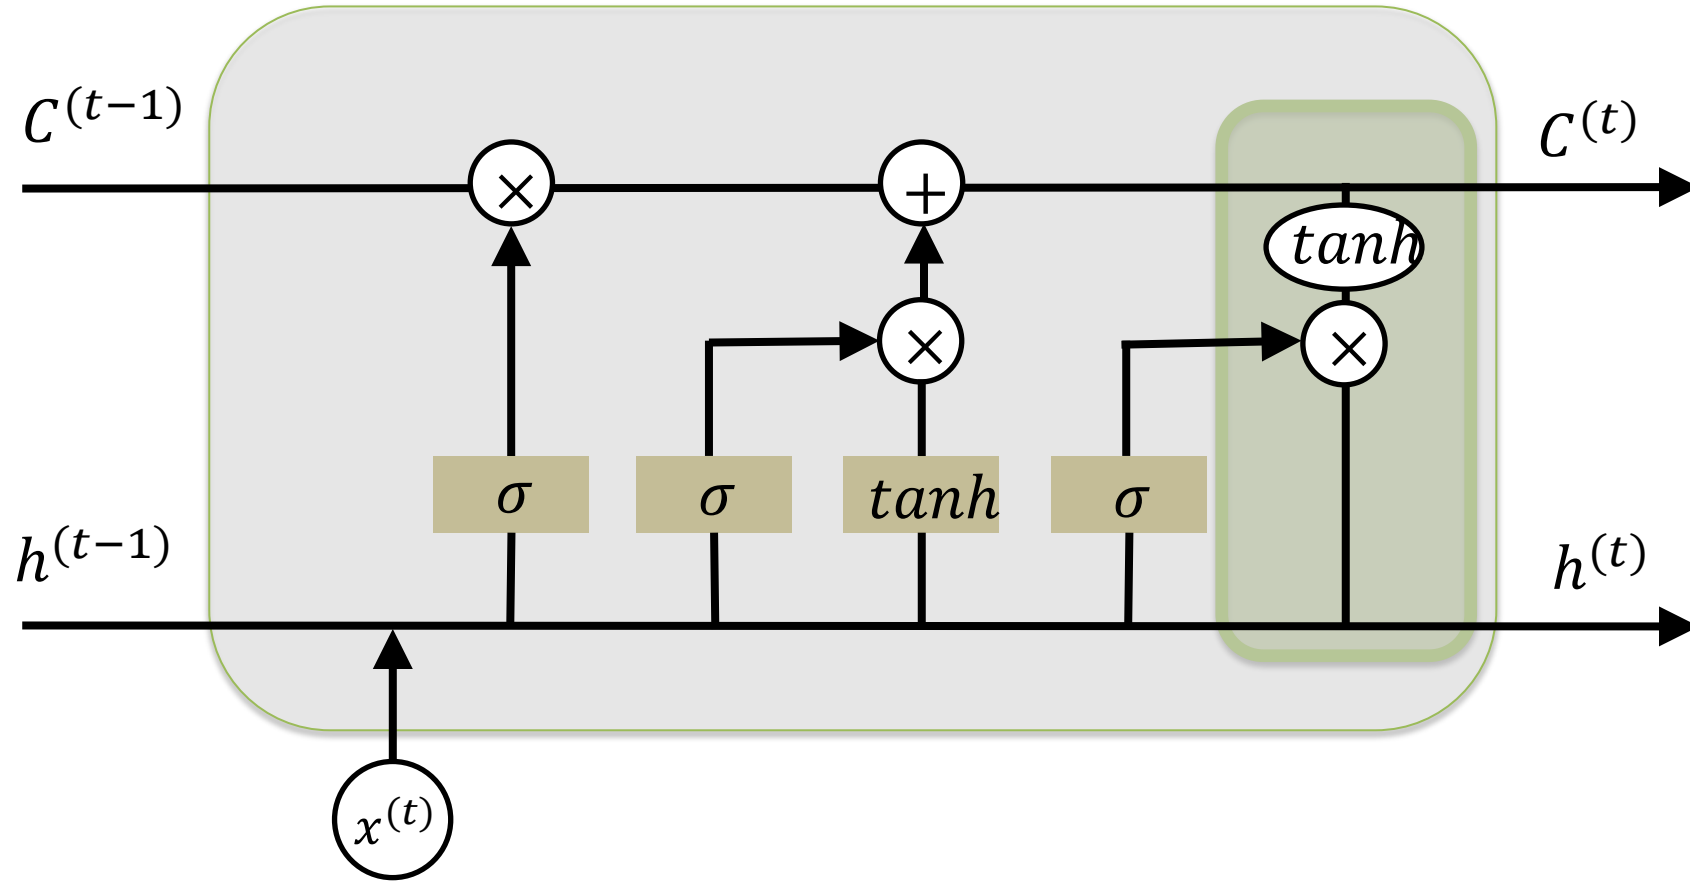


LSTM: 输出门



$$o_t = \sigma \left(\mathbf{W}_o \cdot \mathbf{x}^{(t)} + \mathbf{U}_o \cdot \mathbf{h}^{(t-1)} + \mathbf{b}_o \right)$$








$$h^{(t)} = o_t \odot \tanh \left(C^{(t)} \right)$$





LSTM VS Tree-LSTM





LSTM VS Tree-LSTM



$$\tilde{\mathbf{h}}^{(k)} = \sum_{v_j \in \mathcal{N}_c(v_k)} \mathbf{h}^{(j)}$$

$$\mathbf{f}_{kj} = \sigma(\mathbf{W}_f \cdot \mathbf{x}^{(k)} + \mathbf{U}_f \cdot \mathbf{h}^{(j)} + \mathbf{b}_f) \quad \text{for } v_j \in \mathcal{N}_c(v_k)$$


$$\mathbf{i}_k = \sigma(\mathbf{W}_i \cdot \mathbf{x}^{(k)} + \mathbf{U}_i \cdot \tilde{\mathbf{h}}^{(k)} + \mathbf{b}_i)$$

$$\mathbf{o}_k = \sigma(\mathbf{W}_o \cdot \mathbf{x}^{(k)} + \mathbf{U}_o \cdot \tilde{\mathbf{h}}^{(k)} + \mathbf{b}_o)$$

$$\tilde{\mathbf{C}}^{(k)} = \tanh(\mathbf{W}_c \cdot \mathbf{x}^{(k)} + \mathbf{U}_c \cdot \tilde{\mathbf{h}}^{(k)} + \mathbf{b}_c)$$

$$\mathbf{C}^{(k)} = \mathbf{i}_t \odot \tilde{\mathbf{C}}^{(k)} + \sum_{v_j \in \mathcal{N}_c(v_k)} \mathbf{f}_{kj} \odot \mathbf{C}^{(j)}$$

$$\mathbf{h}^{(k)} = \mathbf{o}_t \odot \tanh(\mathbf{C}^{(k)}).$$



 图上的循环神经网络


 图上的自编码器

 图上的变分自编码器

 图上的生成对抗网络




自编码器




编码器

解码器



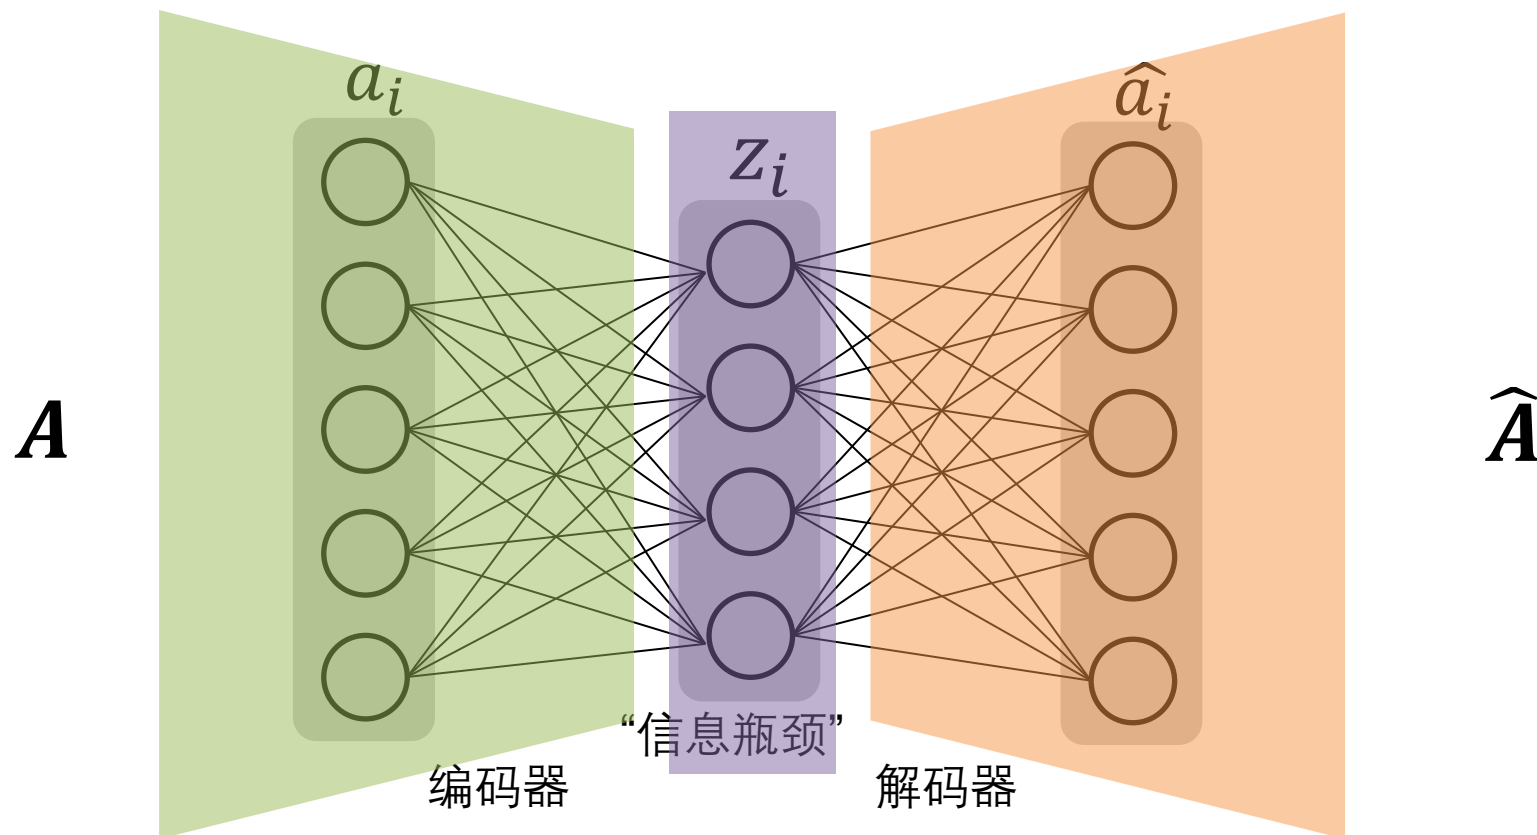


自编码器



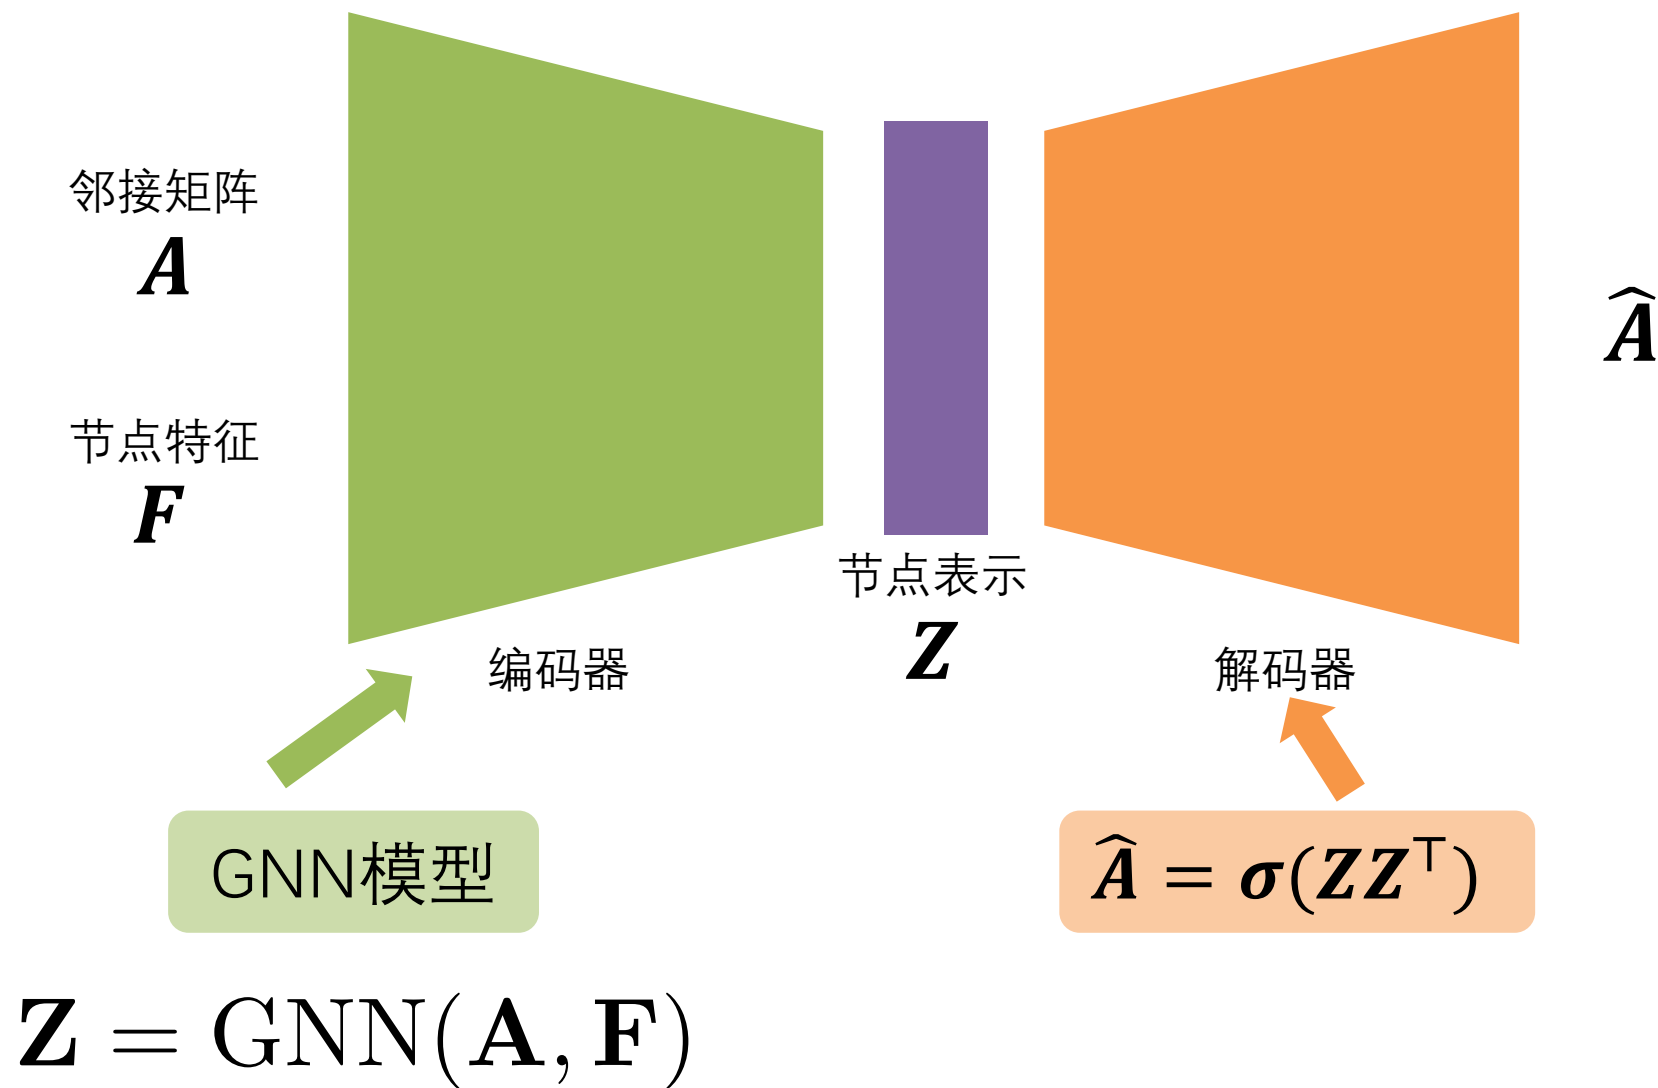


图上的自编码器



$$\sum_{v_i \in \mathcal{V}} \|a_i - \hat{a}_i\|_2^2 \quad \sum_{v_i, v_j \in \mathcal{V}} A_{i,j} \cdot \|z_i - z_j\|_2^2 \quad \|\Theta_{\text{enc}}\|_2^2 + \|\Theta_{\text{dec}}\|_2^2$$

基于图神经网络的图上的自编码器



 图上的循环神经网络


 图上的自编码器

 图上的变分自编码器

 图上的生成对抗网络




变分自编码器



$$\underbrace{\mathbb{E}_{q(z|x_i;\Phi)} [\log p(\mathbf{x}_i | z; \Theta)]}_{\text{重建}}$$

用于节点表示学习的变分自编码器




$$\begin{aligned}\mu &= \text{GNN}(\mathbf{F}, \mathbf{A}; \Phi_{\mu}) \\ \log \sigma &= \text{GNN}(\mathbf{F}, \mathbf{A}; \Phi_{\sigma})\end{aligned}$$


$$\begin{aligned}p(\mathbf{A}_{i,j} = 1 \mid \mathbf{z}_i, \mathbf{z}_j) \\ \sigma(\mathbf{z}_i^{\top} \mathbf{z}_j)\end{aligned}$$



图生成



图的表示:



A

连接

F

节点类型


E

边类型






用于图生成的变分自编码器



$$\mu = \text{pool}(\text{GNN}_{\mu}(\mathcal{G}))$$
$$\log \sigma = \text{pool}(\text{GNN}_{\sigma}(\mathcal{G}))$$


$$\tilde{\mathcal{G}} = \text{MLP}(\mathbf{z}; \Theta)$$



 图上的循环神经网络

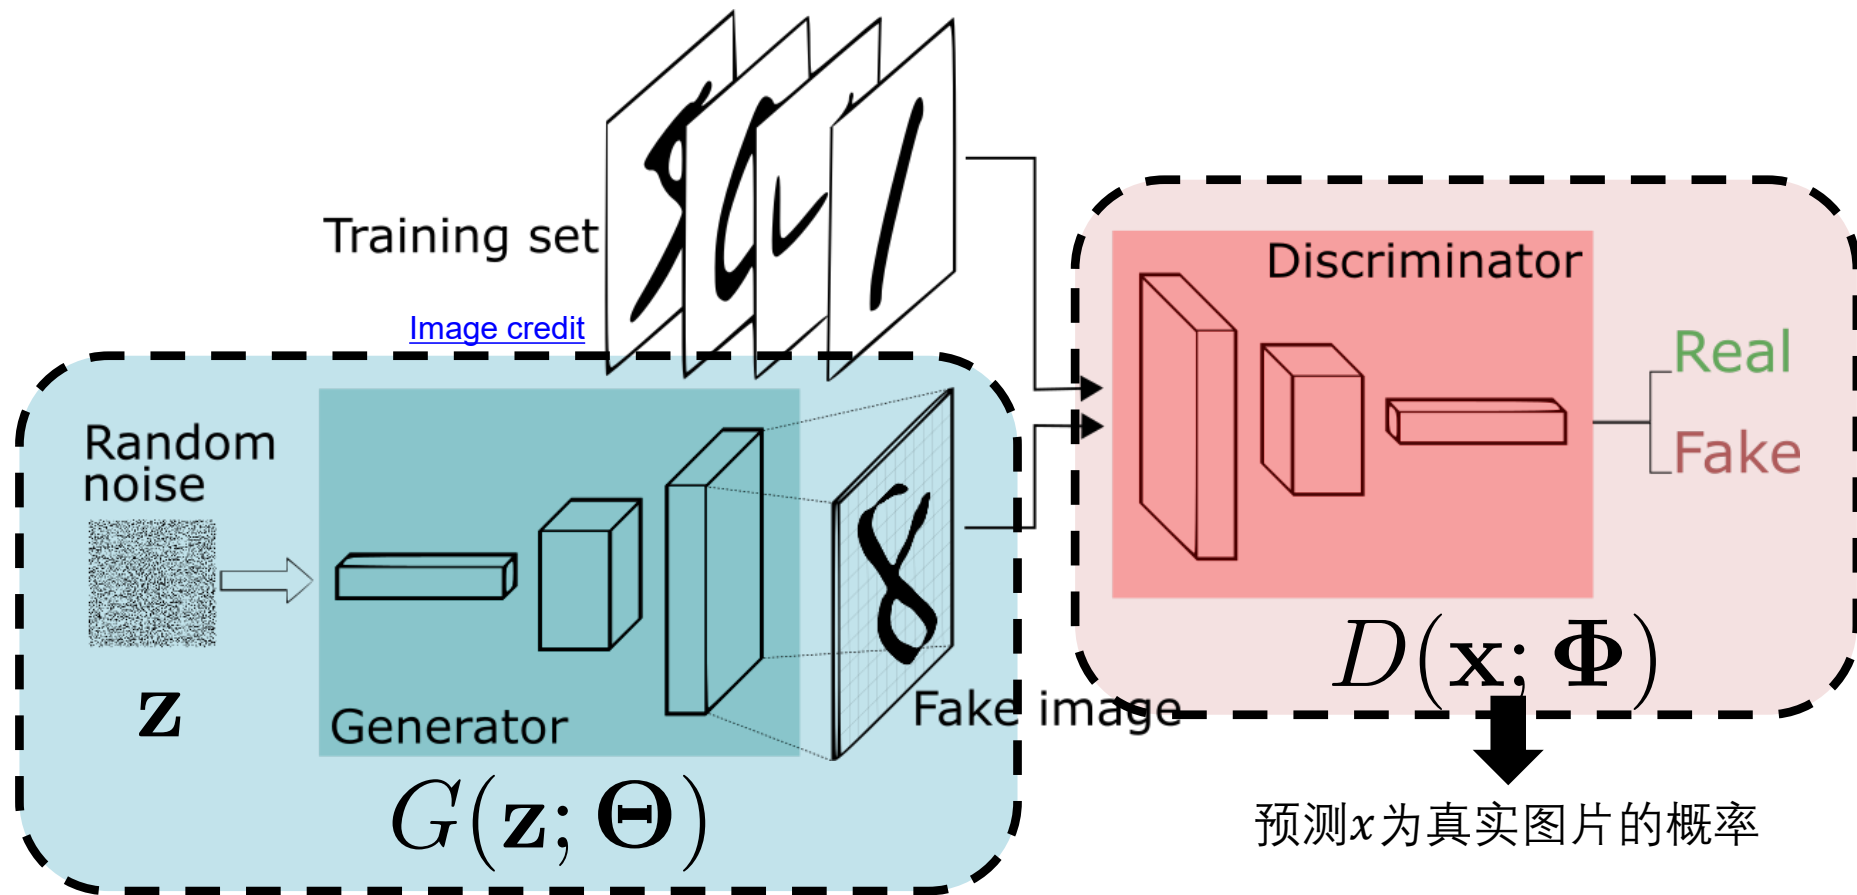
 图上的自编码器

 图上的变分自编码器

 图上的生成对抗网络



生成对抗网络 (GANs)



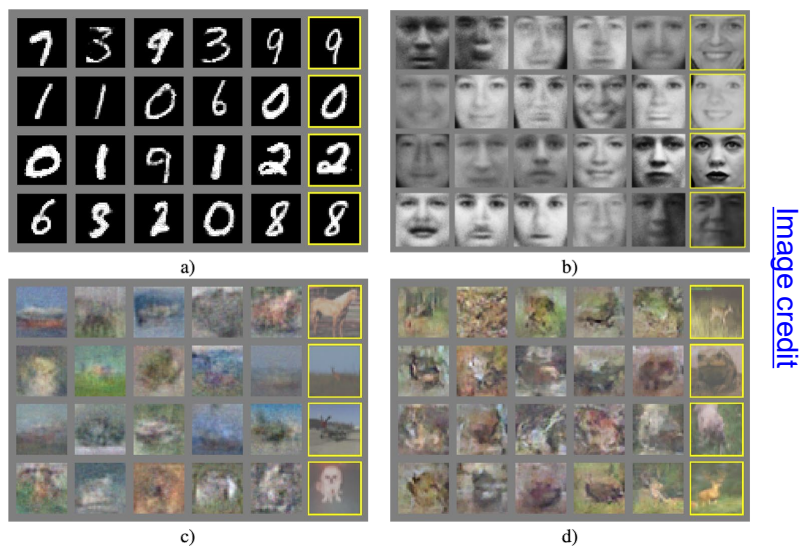
$$\min_{\Theta} \max_{\Phi} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x}; \Phi)] + \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} [\log(1 - D(G(\mathbf{z}; \Theta); \Phi))]$$

真实图片

生成的图片



生成对抗网络的一些应用场景




由GANs生成的图片



基于GANs的风格转换

用于节点表示学习的生成对抗网络

Φ 和 Θ 都可以作为节点表示



判别器

- ❑ 判断给定的一个节点对是否在原图中相连
- ❑ 目标：尽量区分采样出来“邻居”和原图中的真实的邻居。

生成器


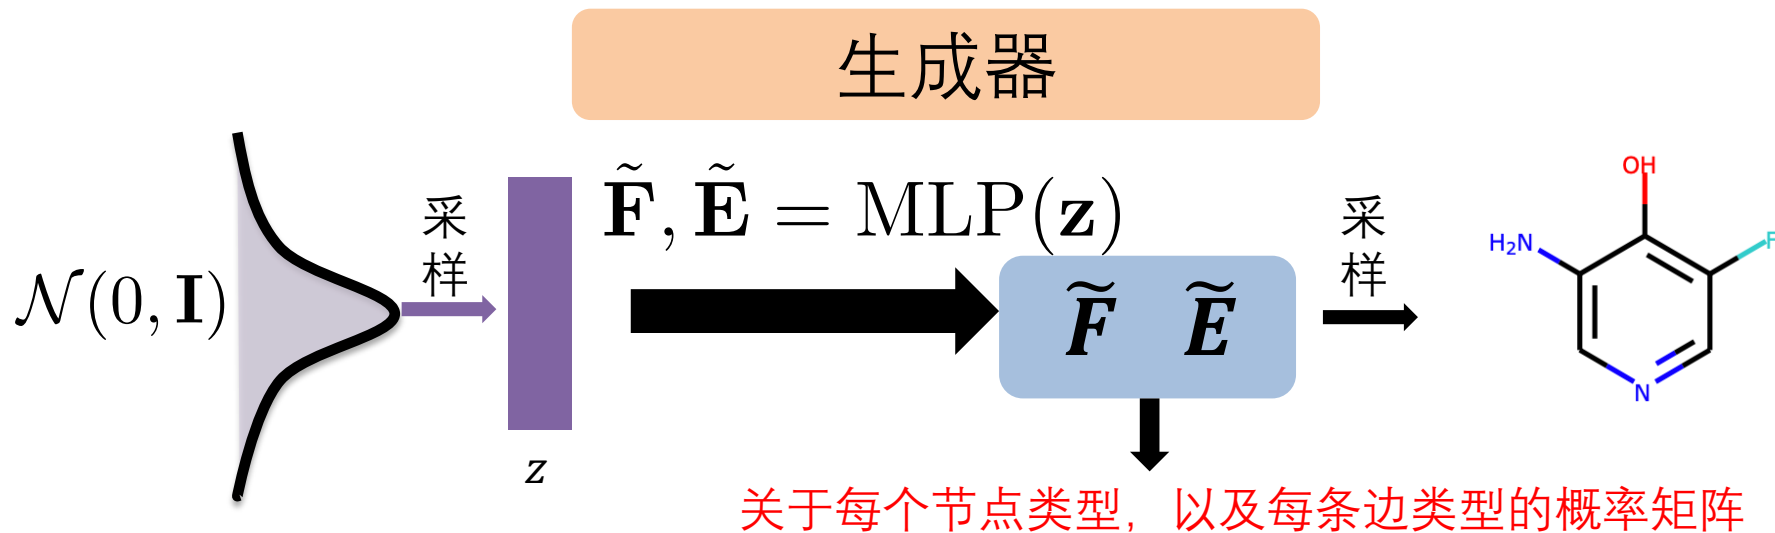
- ❑ 采样一个节点作为 v_i 的“邻居”
- ❑ 目标：使的采样出来的节点尽可能是真的邻居

$$G(v_j | v_i; \Theta) = \frac{\exp(\theta_j^\top \theta_i)}{\sum_{v_k \in \mathcal{V}} \exp(\theta_k^\top \theta_i)}$$

$$D(v_j, v_i; \Phi) = \frac{1}{1 + \exp(-\phi_j^\top \phi_i)}$$




用于图生成的生成对抗网络



 图上的循环神经网络

 图上的自编码器

 图上的变分自编码器

 图上的生成对抗网络

感谢聆听！

Thanks for Listening

